UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

CENTRO DE TECNOLOGIA

DEPARTAMENTO DE ENGENHARIA ELÉTRICA

ELE0604 - REDES NEURAIS ARTIFICIAIS

Trabalho 1: Análise Exploratória de Dados

Análise Exploratória de Dados

UEFA Nations League 2026/27

Preparação de um conjunto para classificação
da posição tática do jogador

Leonardo Barbosa

Matheus Salviano

Prof. Allan Martins

Natal, RN

Novembro de 2026

Sumário

Resumo 2

1. Descrição do conjunto de dados **2**
1.1 Origem e conteúdo 2
1.2 Escolha da tabela de trabalho 3
1.3 Vazamento nas tabelas de partida 3

2. Definição da tarefa de aprendizado **3**

3. Análise exploratória **3**
3.1 Estrutura e tipos 3
3.2 Valores ausentes: um bloco estrutural 4
3.3 Inconsistências de preenchimento 4
3.4 Redundância estrutural e erros na fonte 5
3.5 Zero-inflação e suporte 5
3.6 O confundidor de exposição 5
3.7 Separabilidade por posição 7
3.8 Multicolinearidade 8
3.9 Outliers 8
3.10 Projeção em duas dimensões 8

4. Resumo da análise **10**
4.1 Principais achados 10
4.2 Colunas descartadas 10

5. Conjunto final e preparação **11**
5.1 Pendências para o trabalho 2 11

Referências **12**

Resumo

Este trabalho analisa o conjunto *UEFA Nations League 2026/27* com o objetivo de preparar um problema de aprendizado supervisionado para o trabalho seguinte da disciplina. Todo o código, o notebook executado e as figuras estão em `github.com/leonardolima013/ELE0604-redes-neurais-EDA`. Após avaliar as sete tabelas disponíveis, apenas uma delas, `players_summary.csv`, com 1.468 jogadores e 44 colunas, possui volume compatível com o treinamento de uma rede neural. A tarefa definida é a **classificação da posição tática do jogador** em quatro classes a partir das suas métricas de desempenho.

A análise identificou que 16% das linhas pertencem a jogadores convocados que nunca entraram em campo e não possuem métrica alguma; que todas as contagens eram dominadas pelo tempo de permanência em campo, exigindo normalização por 90 minutos; que três colunas foram preenchidas com zero em lugar de ausência; e que `passes_accuracy` não é reprodutível a partir das colunas que a definem. Foram descartadas 18 das 44 colunas, por identificação, suporte insuficiente, redundância estrutural ou exposição, restando **25 variáveis de entrada e 1.233 amostras**, divididas de forma estratificada em treino, validação e teste.

---

1. Descrição do conjunto de dados

1.1 Origem e conteúdo

O conjunto *UEFA Nations League 2026* foi publicado no Kaggle sob licença CC BY-SA 4.0 e construído por extração automatizada dos endpoints JSON oficiais da UEFA (`compstats.uefa.com` e `match.uefa.com`). Cobre a fase de liga da edição 2026/27 até a quarta rodada: **54 seleções** distribuídas em quatro divisões (Ligas A, B, C e D), **104 partidas disputadas** e **1.468 jogadores**. São sete arquivos CSV, 266 colunas no total e aproximadamente 2,3 MB, codificados em `utf-8-sig`, escolha do autor que preserva a acentuação de nomes próprios.

Tabela 1: Arquivos do conjunto.

Arquivo	Linhas	Colunas	Conteúdo
`players_summary.csv`	1.468	44	Uma linha por jogador, 38 métricas consolidadas
`players_latest.csv`	11.752	47	As mesmas métricas em formato longo (8 categorias × jogador)
`teams_summary.csv`	54	45	Uma linha por seleção
`teams_latest.csv`	432	48	Formato longo das seleções
`finished_matches.csv`	104	34	Partidas concluídas, com placar, público e estádio
`matches.csv`	156	34	Calendário completo, incluindo 52 jogos futuros
`group_standings.csv`	54	14	Classificação dos grupos

As métricas seguem os oito domínios oficiais da UEFA: tempo em campo, gols, finalizações, distribuição, ataque, defesa, goleiro e disciplina.

1.2 Escolha da tabela de trabalho

A escolha não é estética, é uma restrição estatística. Uma MLP densa com uma única camada oculta de 32 unidades sobre 30 entradas já possui cerca de mil parâmetros; treiná-la com algumas dezenas de amostras produz memorização, não aprendizado.

Entre as sete tabelas, somente `players_summary.csv` oferece volume suficiente. `teams_summary` e `group_standings` têm 54 linhas; `finished_matches` tem 104. As duas tabelas `*_latest` parecem maiores, mas são apenas a versão longa das tabelas `*_summary`: cada jogador aparece em exatamente oito linhas, uma por categoria estatística, e as únicas colunas exclusivas são `source_stat_category`, `scraped_at` e `as_of_date`, todas metadados de coleta. Não há métrica nova, logo não há amostra nova.

1.3 Vazamento nas tabelas de partida

Ainda que o volume permitisse, as tabelas de partida trazem um segundo obstáculo. Em `finished_matches.csv`, as colunas `home_score`, `away_score`, `total_goals`, `goal_difference`, `winner_team_name`, `winner_team_id`, `home_points` e `away_points` são funções determinísticas do rótulo `result`: a verificação reconstruiu `result` a partir do placar em **104 de 104 linhas**. Já `group_standings.csv` e `teams_summary.csv` são agregados calculados *depois* de todas as partidas; usá-los como entrada para prever partidas já disputadas configura vazamento temporal.

2. Definição da tarefa de aprendizado

A tarefa escolhida é a **classificação multiclasse da posição tática do jogador** (`GOALKEEPER`, `DEFENDER`, `MIDFIELDER`, `FORWARD`) a partir das suas métricas de desempenho normalizadas. A hipótese de fundo é que a função tática de um jogador deixa uma assinatura estatística recuperável: o goleiro defende, o zagueiro corta, o meia distribui, o atacante finaliza.

O formato corresponde diretamente ao que foi apresentado em aula: um vetor de entrada $x \in \mathbb{R}^{25}$, uma rede densa, saída `softmax` sobre quatro classes e treinamento por backpropagation minimizando uma função de custo. O baseline a superar é a frequência da classe majoritária, **38,4%**.

Toda a análise que segue existe para construir esse par (x, y): identificar quais colunas podem compor x, verificar que nenhuma delas vaza y, corrigir o que distorce a comparação entre jogadores e deixar os dados na escala que as funções de ativação exigem.

3. Análise exploratória

3.1 Estrutura e tipos

A tabela tem 44 colunas: seis de identificação (`player_id`, `player_name`, `country_code`, `position`, `team_id`, `team_name`) e 38 métricas, todas numéricas em ponto flutuante. Não há colunas textuais disfarçadas de numéricas nem separadores decimais inconsistentes.

3.2 Valores ausentes: um bloco estrutural

Quase todas as métricas apresentam exatamente **235 valores nulos**, nas mesmas linhas. Não é ruído de coleta: são jogadores **convocados que não entraram em campo**. Constam da lista da UEFA, mas não produziram estatística alguma.

O recorte por posição é revelador: **54% de todos os goleiros do torneio nunca jogaram** (101 de 187), contra 7% dos atacantes. É consequência direta da regra do futebol, já que cada seleção leva três goleiros e usa um. A assimetria é informação real sobre o torneio, mas inútil como entrada, porque essas linhas não têm nenhuma métrica para alimentar a rede. Foram removidas.

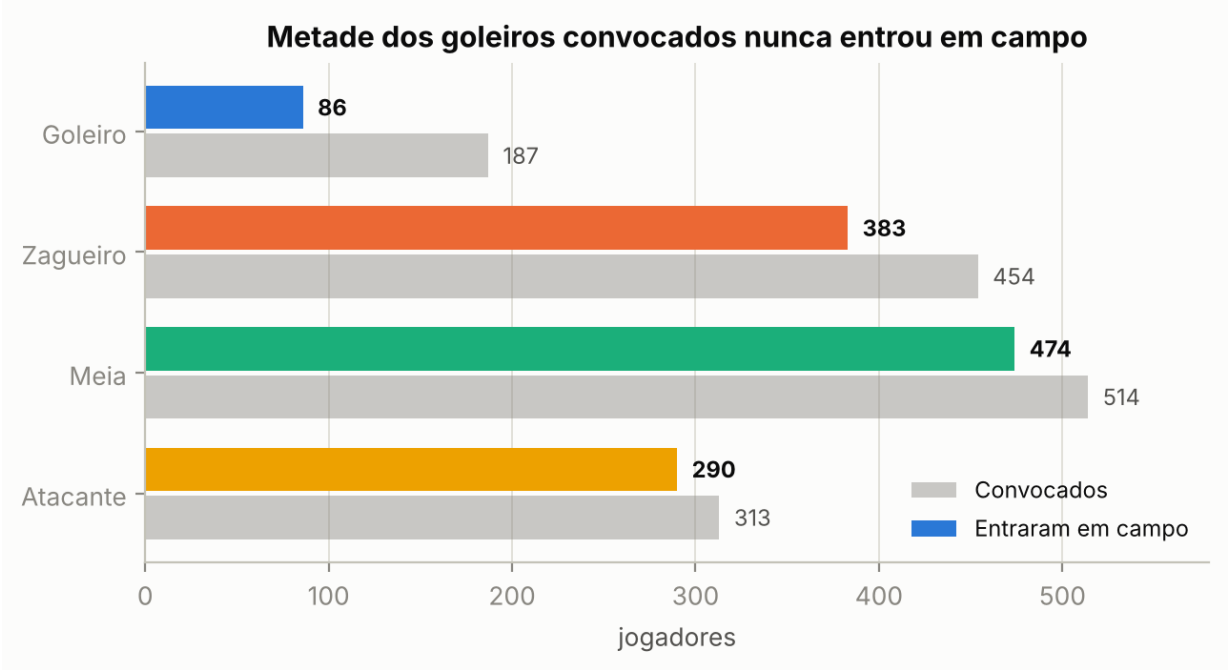


Figura 1: Efeito do filtro sobre a distribuição das classes.

O filtro altera o problema de forma relevante: `GOALKEEPER` cai de 12,7% para **7,0% das amostras (86 jogadores)**, tornando-se classe minoritária, e o baseline majoritário sobe de 35,0% para 38,4%.

Duas colunas têm 305 nulos em vez de 235: `top_speed` e `distance_covered`. Os 70 casos adicionais são dados de rastreamento que a UEFA não publicou, distribuídos por todas as posições (5,7% das linhas restantes).

3.3 Inconsistências de preenchimento

Três colunas fogem do padrão de 235 nulos: `cross_accuracy` (nenhum nulo), `yellow_cards` e `red_cards` (dois cada). Nelas o autor do conjunto gravou **zero onde deveria haver ausência**, tornando indistinguíveis "não cruzou" e "não jogou". Se as 235 linhas fossem mantidas, essas colunas carregariam o sinal falso de um jogador que nunca errou um cruzamento.

Há ainda um caso de **jogador duplicado**: 1.468 identificadores distintos para 1.467 nomes. O mesmo atleta aparece com dois `player_id` e posições conflitantes (`MIDFIELDER` e `FORWARD`), registrado em duas convocações. A linha sem minutos é eliminada pelo filtro da seção anterior, mas o episódio mostra que `player_id` não é chave confiável de pessoa.

3.4 Redundância estrutural e erros na fonte

Três grupos de colunas são somas exatas de outros. Não é correlação alta, mas **redundância perfeita**, que inflaria a dimensão de entrada sem acrescentar informação:

- `goals` = `goals_scored_with_right` + `with_left` + `head` + `other`
- `goals` = `goals_scored_inside_penalty_area` + `outside_penalty_area`
- `attempts` = `attempts_on_target` + `off_target` + `blocked`

Testar essas identidades produziu um achado adicional: **cinco linhas não fecham**. São erros da fonte: gols sem parte do corpo ou região atribuída, e finalizações cujas parcelas não somam o total informado.

A coluna `passes_accuracy` merece atenção à parte. Recalculando a razão $100 \times$ `passes_completed`/`passes_attempted`, o erro mediano é de 0,63 p.p., compatível com arredondamento, mas apenas **59% das linhas ficam dentro de ±1 p.p.**, e o percentil 95 chega a 13,6 p.p. No extremo há um grupo de jogadores com aproveitamento perfeito gravado como 50%. Como a precisão é derivável das outras duas colunas, foi **recalculada**, o que também resolve o preenchimento inconsistente da seção anterior.

Finalmente, `punches` é **constante zero** para todos os 1.233 jogadores que entraram em campo: variância nula, incapaz de distinguir qualquer coisa e capaz de quebrar a padronização por divisão por zero.

3.5 Zero-inflação e suporte

A maioria das métricas é uma contagem rara, e convém separar dois fenômenos distintos que a esparsidade pode esconder.

A esparsidade por si só **não** desqualifica uma coluna: `saves` é 93,4% zeros e ainda assim é o melhor discriminador de todo o conjunto, porque os zeros são exatamente os jogadores de linha. O que desqualifica é o **suporte insuficiente**, ou seja, poucas observações não nulas para extrair qualquer regularidade. Adotou-se o critério explícito de **menos de 2% de observações não nulas** (menos de 25 dos 1.233 jogadores), que elimina cinco colunas: `goals_scored_other` e `saves_on_penalty` (5 observações cada), `penalty_scored` (14), `red_cards` (20) e `punches` (nenhuma).

3.6 O confundidor de exposição

Este é o achado central da análise. Toda métrica de contagem depende de **quanto tempo o jogador permaneceu em campo**, que varia de 1 a 360 minutos no conjunto. Sem corrigir isso, a rede aprenderia a distinguir titular de reserva em vez de zagueiro de meia.

Antes da correção, `distance_covered` tem $r = 0{,}83$ com os minutos e `passes_attempted` $r = 0{,}81$: essas colunas mediam sobretudo tempo de jogo. Após a divisão por 90 minutos, as correlações colapsam para a faixa de $\pm 0{,}1$ e o que resta em cada coluna é uma **taxa de atuação**, comparável entre titular e reserva.

A redução não é uniforme, e vale registrar a exceção: `distance_covered` passa de $+0{,}83$ para $-0{,}39$, invertendo o sinal em vez de zerar, e as demais correlações residuais são todas levemente negativas. Ambos os efeitos têm a mesma causa: quem joga poucos minutos entra na fase final da partida, em ritmo acima da média, o

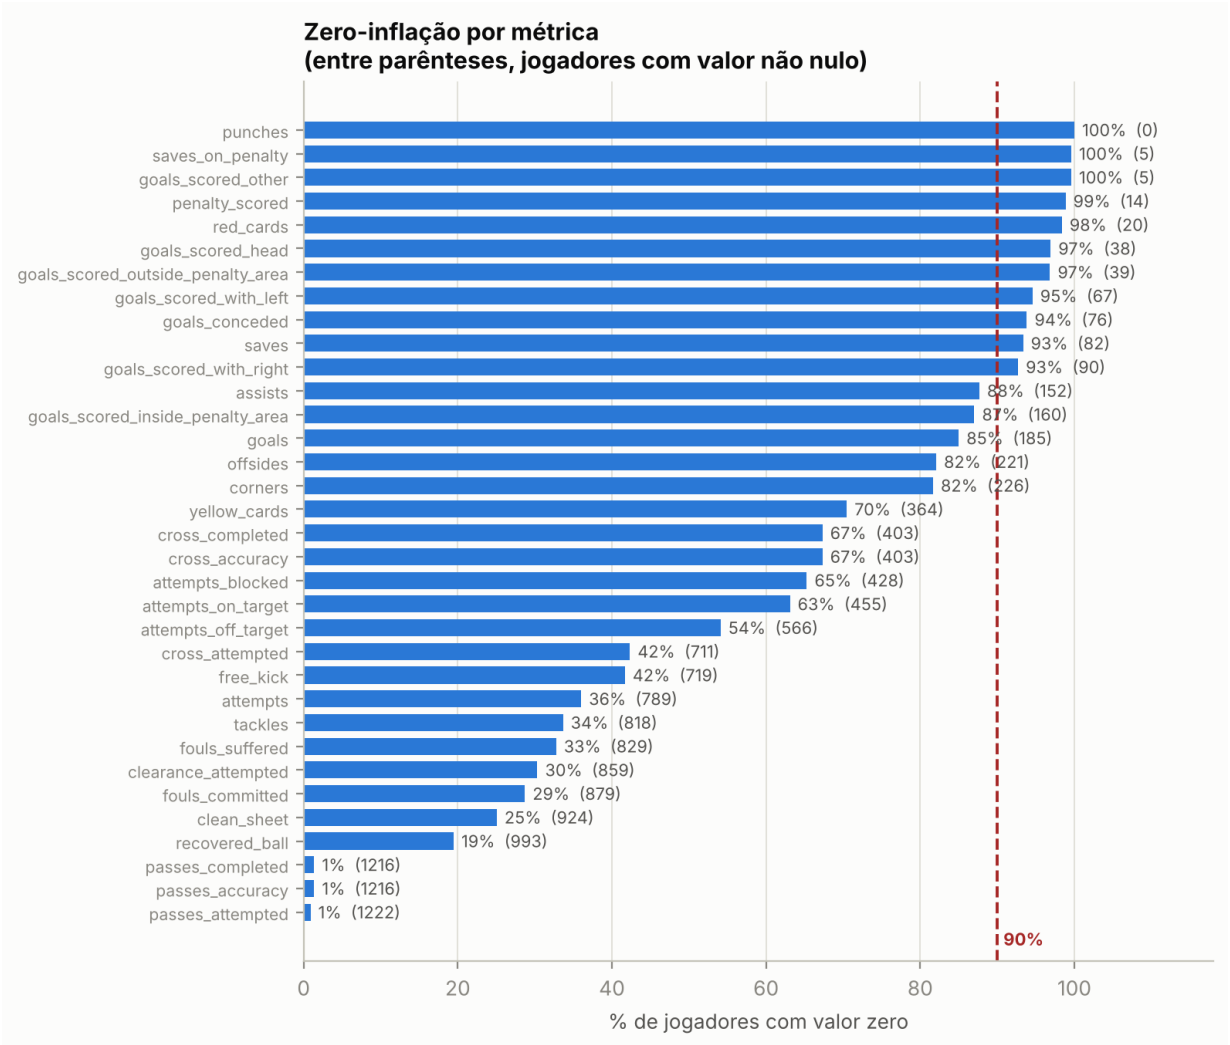


Figura 2: Proporção de zeros em cada métrica, com o número de observações não nulas entre parênteses.

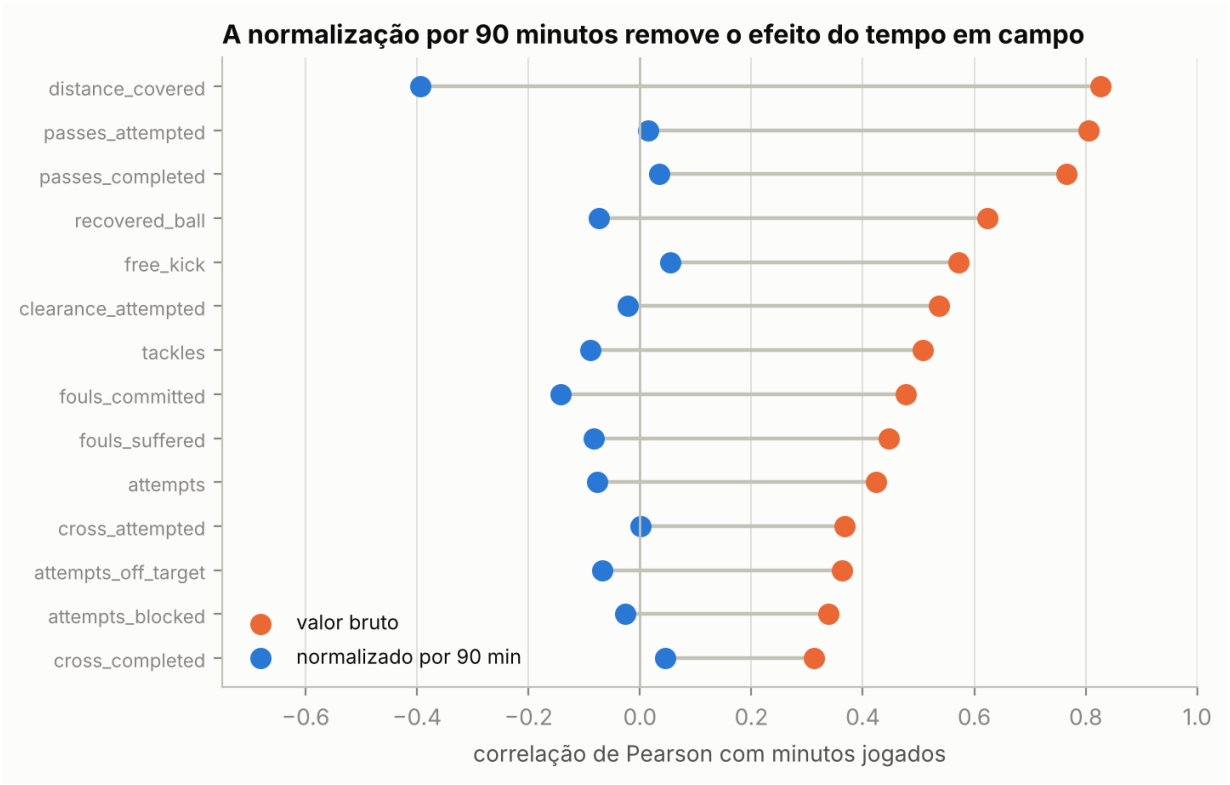


Figura 3: Correlação de cada métrica com os minutos jogados, antes e depois da normalização.

que infla a taxa quando dividida por um denominador pequeno. O mesmo fenômeno reaparece como outliers na seção 3.9.

3.7 Separabilidade por posição

Com as taxas no lugar, a pergunta é se essas colunas de fato distinguem as quatro posições. A medida usada é a razão F da ANOVA, variância entre classes sobre variância dentro das classes.

O padrão geral corresponde ao esperado de um jogo de futebol: defesas e velocidade máxima baixa isolam o goleiro, cortes marcam o zagueiro, volume de passe marca o meia e finalização marca o atacante. Entre zagueiro, meia e atacante há sobreposição clara, e é aí que reside o problema de aprendizado de verdade.

Dois resultados merecem destaque.

O atalho do bloco de goleiro. A métrica `saves` tem $F = 1251$, é não nula em 82 dos 86 goleiros e em **zero** dos 1.147 jogadores de linha. Uma única regra `saves > 0` classifica goleiros com 95,3% de acerto. Isso precisa constar do relatório do modelo: a acurácia global parecerá alta por conta de uma classe trivialmente separável. A recomendação é reportar a **matriz de confusão** e executar um segundo experimento restrito a jogadores de linha, onde o problema é genuinamente difícil.

Um resultado negativo. Desarmes por 90 minutos quase não separam posição ($F = 3{,}4$, contra $F = 1251$ das defesas): zagueiros e meias desarmam em taxa praticamente idêntica. A intuição de que "desarme é coisa de zagueiro" não se sustenta nos dados: o que distingue o zagueiro é o **corte**, não o desarme.

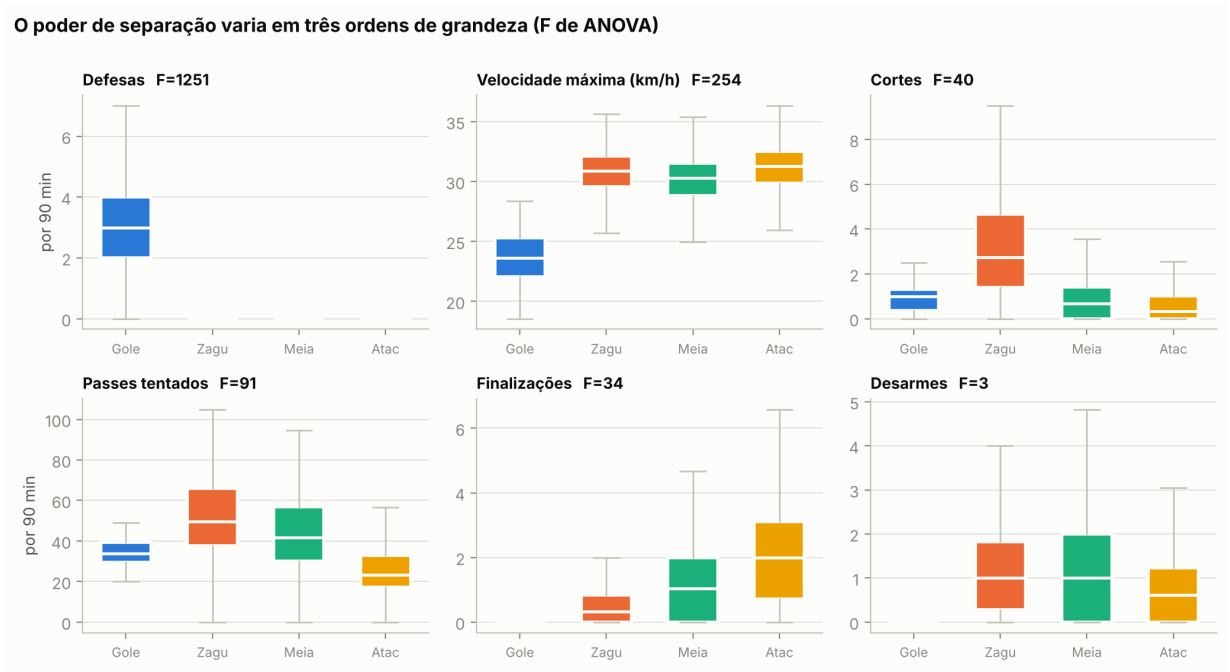


Figura 4: Distribuição de seis métricas por posição, com o respectivo valor de F.

3.8 Multicolinearidade

Além das identidades exatas, há pares com correlação elevada que duplicam informação.

A estrutura em blocos é nítida: a redundância se concentra dentro de cada domínio métrico. `passes_attempted` e `passes_completed` mantêm $r = 0{,}98$ mesmo após a normalização, então o par carrega uma informação só. Foram preservados o **volume** (`attempted`) e a **qualidade** (`accuracy` recalculada), descartando `completed`: a mesma dupla reconstrói o par original sem a colinearidade. A lógica se repete para os cruzamentos.

3.9 Outliers

Padronizando as 25 variáveis, 9,3% das linhas apresentam ao menos uma com $|z| > 5$. A causa dominante é **amostra curta**: os casos mais extremos têm 1 ou 2 minutos em campo. Um jogador que entrou por um minuto e deu um carrinho registra 90 desarmes por 90 minutos, taxa aritmeticamente correta e sem sentido prático.

Como esses valores representam jogadores reais e não erro de medição, removê-los descartaria sinal. A opção adotada foi **winsorizar**: recortar cada variável nos percentis 1 e 99, limitando o extremo sem eliminar a linha.

3.10 Projeção em duas dimensões

A PCA responde visualmente se as classes ocupam regiões distintas do espaço de entrada, e antecipa o que uma camada densa faz: projetar em menos dimensões.

Os goleiros formam um **braço inteiramente apartado**, estendendo-se para PC1 alto e PC2 baixo, o que confirma visualmente o atalho da seção 3.7. As cargas explicam o eixo: a PC1 é dominada por defesas ($+0{,}39$), gols sofridos ($+0{,}37$) e

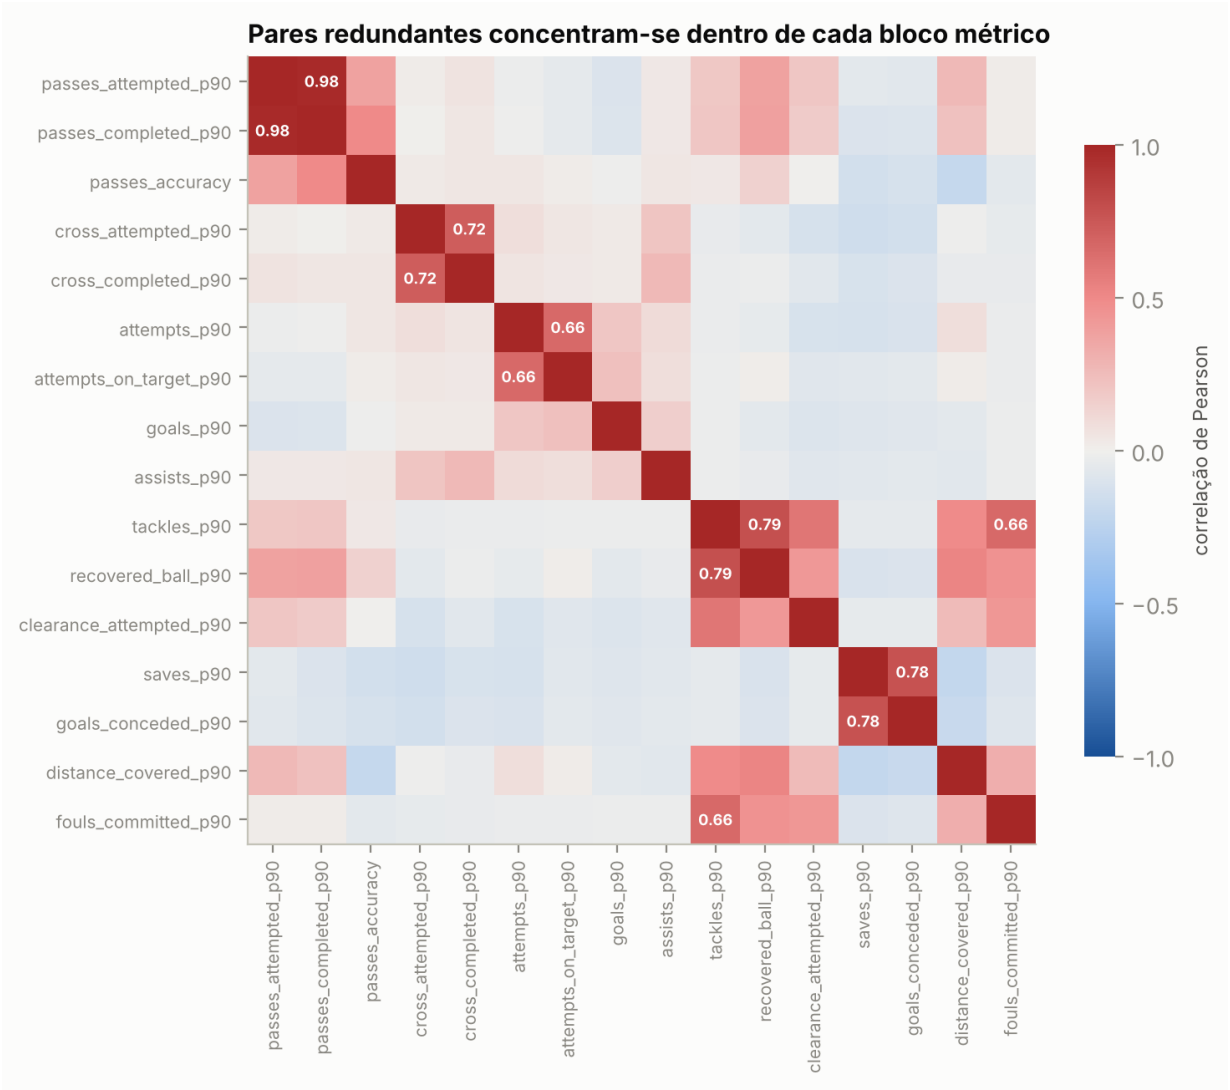


Figura 5: Matriz de correlação entre as métricas normalizadas.

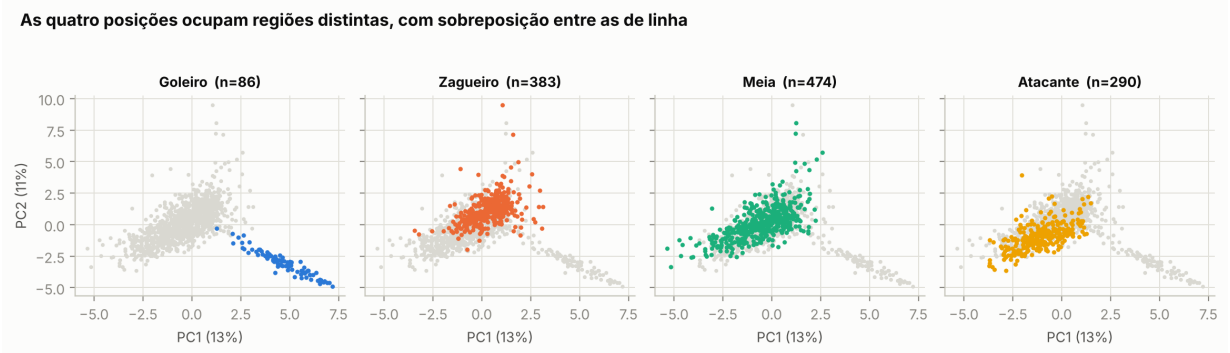


Figura 6: Projeção nas duas primeiras componentes principais, após winsorização. Em cinza, as demais posições.

velocidade máxima baixa ($-0{,}36$). Ela não é um eixo tático de campo, é o eixo goleiro *versus* jogador de linha.

Entre os jogadores de linha a estrutura aparece na PC2, carregada por bola recuperada ($+0{,}45$), passes tentados ($+0{,}31$) e cortes ($+0{,}29$): zagueiros ocupam a faixa superior, atacantes a inferior-esquerda e os meias se espalham por toda a região intermediária, sobrepondo-se aos dois.

Dois números reforçam a escolha do modelo: PC1 e PC2 juntas explicam apenas **23,7%** da variância, e são necessárias dez componentes para alcançar 66%. A informação que distingue as posições está distribuída por muitas dimensões e não é linearmente separável, que é exatamente o caso em que uma camada oculta com ativação não linear supera um classificador linear.

4. Resumo da análise

4.1 Principais achados

1. **235 jogadores (16%) nunca entraram em campo** e não possuem métrica alguma. Entre os goleiros a proporção chega a 54%. Removidos: $n = 1.468 \rightarrow 1.233$, com `GOALKEEPER` caindo de 12,7% para 7,0% das amostras.
2. **O tempo em campo dominava todas as contagens** ($r = 0{,}83$ para distância percorrida). A normalização por 90 minutos é a transformação mais importante de toda a preparação.
3. **Três colunas foram preenchidas com zero em vez de ausência**, o que criaria sinal falso.
4. **`passes_accuracy` não é reprodutível** a partir das colunas que a definem: apenas 59% das linhas ficam dentro de ±1 p.p. do valor recalculado. A coluna foi recalculada.
5. **Redundâncias estruturais:** `goals` é soma exata de quatro colunas, `attempts` de três, e `passes_attempted`↔`passes_completed` mantêm $r = 0{,}98$ após a normalização.
6. **Cinco linhas com erro na fonte**, reveladas pelos testes de identidade.
7. **Um jogador duplicado** com dois identificadores e posições conflitantes.
8. **A esparsidade não é defeito; a falta de suporte é.** `saves` tem 93% de zeros e é o melhor discriminador do conjunto, enquanto `goals_scored_other` tem 5 observações e não sustenta aprendizado.
9. **`GOALKEEPER` é trivialmente separável:** `saves > 0` acerta 95,3% dos goleiros e nunca dispara em jogador de linha.
10. **Desarmes quase não separam posição** ($F = 3{,}4$); o que marca o zagueiro é o corte.
11. **Jogadores de poucos minutos ocupam toda a cauda da primeira componente**, exigindo winsorização.
12. **A informação está distribuída por muitas dimensões:** 23,7% em duas componentes e 66% em dez, o que justifica tecnicamente uma MLP com camada oculta.

4.2 Colunas descartadas

Foram eliminadas **18 das 44 colunas**, além do alvo `position`, segundo quatro critérios.

Tabela 2: Colunas removidas e respectivos motivos.

Critério	Colunas	Motivo
Identificação	`player_id`, `player_name`, `team_id`	Permitiriam memorizar o indivíduo em vez de aprender o padrão
Identificação	`team_name`, `country_code`	54 níveis categóricos (~23 jogadores cada); a seleção não define a função tática, e `country_code` duplica `team_name`
Suporte < 2%	`punches`	Constante zero entre os 1.233 que jogaram (variância nula)
Suporte < 2%	`goals_scored_other`, `saves_on_penalty`	5 observações não nulas cada
Suporte < 2%	`penalty_scored`, `red_cards`	14 e 20 observações não nulas
Redundância	`goals`	Soma exata das quatro colunas por parte do corpo
Redundância	`goals_scored_inside_penalty_area`, `goals_scored_outside_penalty_area`	Segunda decomposição do mesmo total
Redundância	`attempts`	Soma exata de `on_target` + `off_target` + `blocked`
Redundância	`passes_completed`, `cross_completed`	$r = 0{,}98$ e $r = 0{,}72$ com a coluna de volume; a qualidade já está nas colunas de precisão
Exposição	`minutes_played_official`, `matches_appearance`	Tornam-se o denominador da normalização, não entrada

5. Conjunto final e preparação

Restaram **25 variáveis de entrada e 1.233 amostras**. Todas as contagens foram convertidas em taxas por 90 minutos; `passes_accuracy` e `cross_accuracy` foram recalculadas; `top_speed` permaneceu em sua unidade original.

A divisão é **estratificada** em 70% treino (863), 15% validação (185) e 15% teste (185), os três conjuntos pedidos em aula. A estratificação é necessária porque `GOALKEEPER` tem apenas 86 amostras: uma divisão aleatória simples poderia deixar o teste com pouquíssimos goleiros. As proporções das quatro classes ficaram preservadas dentro de 0,5 ponto percentual em cada conjunto.

Winsorização e padronização foram **ajustadas somente no conjunto de treino** e então aplicadas aos outros dois. Calcular percentis ou médias sobre o conjunto completo faria o teste influenciar o pré-processamento, que é uma forma sutil de vazamento.

O resultado foi salvo em `dados_preparados.npz`, com as matrizes já padronizadas e os rótulos em codificação *one-hot*, prontos para alimentar a rede.

5.1 Pendências para o trabalho 2

- **Imputação de `top_speed` e `distance_covered`** (5,7% de ausência). A imputação pela mediana *da posição* usaria o rótulo y para construir x e configuraria vazamento; deve ser feita pela mediana global, ajustada apenas no conjunto de treino.
- **Desbalanceamento de `GOALKEEPER`** (86 amostras, 7%): aplicar pesos de classe na função de custo.
- **Experimento restrito a jogadores de linha**, sem a classe trivialmente separável, para medir a dificuldade real do problema.

- **Teste de sensibilidade** com um piso mínimo de minutos jogados, verificando o efeito das taxas infladas por amostra curta.

Referências

- SUBHASH B. *UEFA Nations League 2026* [conjunto de dados]. Kaggle, 2026. Licença CC BY-SA 4.0. Disponível em: https://www.kaggle.com/datasets/subhashb21022/uefa-nations-league-2026
- UEFA. *Competition statistics endpoints*: `compstats.uefa.com` e `match.uefa.com` (fonte primária do conjunto).
- MARTINS, A. *Aprendizado de Máquina e Deep Learning… Na prática!* Notas de aula, DEE/UFRN. Disponível em: `https://dev-mind.blog/ufrn/machine_learning/`